

基于YOLOv8的被动毫米波违禁品实时 检测系统在安检场景下的应用

主题方向： 人工智能 +

专业领域/方向： 电子信息 / 人工智能、计算机视觉

适用课程： 数字图像处理、目标检测算法

作者姓名： XXX、XXX

工作单位： XXX 大学 XXX 学院

中国专业学位案例中心

2026 年 X 月 X 日

案例正文

透视违禁品：被动毫米波安检场景下的 YOLOv8 轻量化实时检测系统研发 *

XXX XXX

摘要：随着高铁站、地铁站、机场、大型活动场馆的人流量持续攀升，安检环节正面临“通过速度”与“检测精度”的双重压力。相比传统主动式毫米波成像仪与 X 光安检仪，被动式毫米波（Passive Millimeter Wave, PMMW）成像技术具有完全无电离辐射、无需主动发射信号、隐私侵扰更小的优势，更适合大客流公共场所的非接触式安全筛查，但 PMMW 图像天然存在空间分辨率低、单帧信息量少、噪声大、隐藏物体尺寸小等固有难题，直接检测的可靠性长期受限。本案例聚焦某高校科研团队与安检设备企业联合开展的“基于 YOLOv8 与 PMMW 的小尺寸违禁品实时检测系统”研发项目，还原团队在基线模型选型、主干网络轻量化、颈部特征融合结构改进、检测头设计等一系列技术路线抉择中的权衡取舍过程：如何在将模型算力开销压缩超过 25% 的同时，将关键的小目标检测精度不降反升；如何面对“轻量化必然伴随精度损失”这一工程直觉，通过特征金字塔多尺度融合与结构重参数化设计实现“鱼与熊掌兼得”。案例同时呈现了团队在数据集构建、消融实验设计、基线模型对比等环节的完整技术决策链条，为计算机视觉、嵌入式人工智能系统课程提供了一个可复现、可讨论的工程范例。

Abstract: As passenger flow at high-speed rail stations, subway stations, airports, and large event venues continues to surge, security screening faces a dual pressure of throughput speed and detection accuracy. Compared with conventional active millimeter-wave imagers and X-ray scanners, Passive Millimeter Wave (PMMW) imaging offers zero ionizing radiation, no active signal emission, and reduced privacy intrusion, making it well suited for non-contact screening in high-traffic public venues. However, PMMW imagery inherently suffers from low spatial resolution, sparse single-frame information, high noise, and extremely small concealed-object sizes. This case follows a joint R&D project between a university research team and a security-screening equipment manufacturer to build a real-time small-object prohibited-item detection system based on YOLOv8 and PMMW imaging, reconstructing the team's technical trade-offs across baseline model selection, backbone

*(1) 本案例系教育部学位与研究生教育发展中心 2024 年度主题案例项目成果（项目名称：XXXX；项目编号：XXXX；首席专家：XXX）。(2) 本案例复制权、发表权、信息网络传播权等相关权益由教育部学位与研究生教育发展中心依法享有，如有相关需要，请取得教育部学位与研究生教育发展中心授权。(3) 本案例只供课堂讨论之用，并无暗示或说明某种行为是否有效。

lightweighting, neck-level feature-fusion redesign, and detection-head design, and how the team overcame the common engineering intuition that lightweighting necessarily degrades accuracy through multi-scale feature pyramid fusion and structural re-parameterization.

关键词：YOLOv8、被动毫米波成像、小目标检测、模型轻量化、特征金字塔

Keywords: YOLOv8; Passive Millimeter Wave Imaging; Small Object Detection; Model Lightweighting; Feature Pyramid Network

作者信息：XXX, XXX 大学 XXX 学院教授; XXX, XXX 大学 XXX 学院硕士研究生。

引言

清晨七点半，某城市地铁换乘枢纽的安检口前，队伍已经排出了几十米。安检员紧盯着屏幕上模糊的灰阶图像——那是被动式毫米波成像仪实时采集的乘客体表信息，没有刺眼的 X 光，也没有需要乘客配合站立数秒的主动毫米波扫描，人流可以“边走边测”地正常通过。但也正因为如此，画面里每一帧图像所携带的信息量都非常有限：分辨率低、对比度差、背景噪声多，藏匿在衣物下的违禁物品往往只有拳头大小甚至更小，稍纵即逝。安检员的眼睛盯得再紧，也难免疲劳、难免漏检，尤其是在早晚高峰连续值守数小时之后。

这正是团队接到的研发任务：能不能让算法替安检员的眼睛去“盯”？而且必须足够快——大客流场景下，人流通过安检口的速度不能因为算法而被拖慢，每一次检测必须在极短的时间窗口内完成，同时还要装得进安检设备有限的边缘计算硬件里，不能依赖云端服务器的强大算力。

团队面前摆着两条看似矛盾的技术要求：精度要够高——被动毫米波图像本就信息稀疏，若检测模型再“看不清”，安检形同虚设；模型要够小、够快——必须能在嵌入式设备上实时运行，不能是一个只能在实验室服务器上跑分的“庞然大物”。传统的工程直觉告诉我们，轻量化几乎总是以牺牲精度为代价；团队要做的，恰恰是打破这个“直觉”，用一条可复现、可推广的工程路径回答：轻量化与高精度检测，究竟能否兼得？

这个问题没有教科书式的标准答案，团队也没有从一开始就找到最终方案——真正呈现在本案例中的，是一条布满权衡、反复验证、甚至包含“走了弯路又主动放弃”的完整技术决策链条。这条链条本身，或许比任何单一的性能数字都更值得计算机专

业学位的学员在课堂上细细拆解：一项工程技术方案的诞生，究竟是灵光乍现的顿悟，还是层层递进的系统性验证？

1. 技术前沿性：从成像原理到检测框架的路线选型

1.1 为什么是被动毫米波，而不是主动式毫米波或 X 光

安检成像技术大致可分为三类。X 光安检仪虽然分辨率高，但存在电离辐射，长期或高频次暴露对人体存在潜在健康风险，且几乎不可能用于“人体安检”场景的持续扫描；主动式毫米波全息成像通过主动发射低功率毫米波信号并接收目标反射，可以获得较高质量的三维成像，但需要乘客配合站立数秒完成扫描，成像速度较慢，难以满足特大客流场景“不停顿通过”的效率要求，且设备成本高昂。团队在项目立项阶段专门对三类技术路线的适用场景做了系统性梳理，形成了“高安全等级、低通过速度要求场所优先选 X 光；高通过速度要求、可接受较高设备成本场所可选主动毫米波；超大客流、成本敏感场所首选被动毫米波”这一初步的技术选型决策框架，为后续同类场景的技术路线选择提供了可复用的参考依据。被动式毫米波成像仅接收人体自身及环境辐射出的毫米波能量、不主动发射任何信号，具有完全无电离辐射、隐私侵扰更小、可实现“动态无感通过”的独特优势，更适合地铁、高铁站等对通过速度要求极高的公共场所。但代价是：被动式毫米波图像的空间分辨率和对比度天然偏低，单帧图像携带的违禁品信息量较少、噪声较多，直接依赖传统的滤波、阈值分割或边缘检测方法进行序列图像处理，难以满足“小尺寸目标 + 高噪声背景 + 实时性”这一组合难题下的可靠检测要求。这也是团队将研发重心投向“前沿性”检测算法而非传统图像处理流水线的根本原因——只有具备强大特征学习能力的深度神经网络，才有可能从稀疏、模糊的被动毫米波图像中提取出足够的判别性特征。

1.2 为什么选 YOLOv8 作为基线模型

目标检测算法大体可分为两阶段检测器（如 Faster R-CNN）和单阶段检测器（如 YOLO 系列、SSD、RetinaNet 等）。两阶段检测器精度通常更高，但推理速度较慢，难以满足安检场景的实时性要求；单阶段检测器则在精度与速度之间取得更好平衡。YOLO 系列历经多代迭代，YOLOv8 作为其中较新的一代，在工业界积累了大量成熟的轻量化改造经验和部署工具链¹，是团队综合考量精度、速度、可部署性后选定的基线框架，这也代表了当前工业级实时检测任务中“站在巨人肩膀上做工程创新”的典

¹YOLOv8 由 Ultralytics 公司开源发布，参见 Jocher, G., Chaurasia, A., Qiu, J. Ultralytics YOLOv8[EB/OL]. GitHub, 2023. <https://github.com/ultralytics/ultralytics>.

型路线选择，而非从零设计全新网络架构。

团队在基线选型阶段也评估过其他轻量化骨干网络方案，例如以 MobileNet 系列、ShuffleNet 系列为代表的移动端专用轻量化网络。这些网络在图像分类任务上有着优秀的效率表现，但团队评估后发现，这类网络的轻量化设计主要针对分类任务的全局特征进行优化，对目标检测任务所依赖的多尺度、细粒度定位特征的保留能力相对有限，直接替换到检测框架的骨干网络中，在小目标检测这类对细节特征高度敏感的任务上往往会出现精度损失过大的问题。这一评估过程本身也是“前沿性”的体现：前沿不代表盲目追新，而是要在充分理解各类技术方案的适用边界后，做出真正匹配任务特性的选择，这也是工程教育中区分“跟风式技术选型”与“论证式技术选型”的关键分水岭。

1.3 数据集与任务的特殊约束

团队使用某高校毫米波成像实验室研发的“SAIR-U”被动毫米波实时成像仪采集的数据集进行训练与验证，该设备工作频段为 Ka 波段（约 34GHz），成像视场 $40\times 22^\circ$ ，成像距离 2.5-5 米，温度灵敏度 $1-2K^2$ 。数据集规模有限，这也是被动毫米波检测任务区别于常规自然图像目标检测任务的又一个现实约束——团队必须在小样本条件下让模型学会识别体积微小、边界模糊的目标，这本身就对模型的特征提取效率提出了远高于常规检测任务的要求，也是本案例“前沿性”的另一层体现：不是简单套用现成模型，而是要针对这一特定成像模态的数据特性进行适配性改造。

1.4 小目标检测：一个尚未被充分解决的前沿难题

小目标检测长期是计算机视觉领域公认的前沿难题之一，其根源在于卷积神经网络逐层下采样的过程中，小目标所占据的像素区域在深层特征图上会被压缩到只剩几个像素、甚至完全消失，导致深层语义特征中几乎不包含小目标的有效信息。在自然图像数据集上，这一问题已经通过多年研究积累了较为成熟的应对手段；但在被动毫米波这一特殊成像模态下，问题变得更加棘手——由于成像分辨率天然偏低，“小目标”在毫米波图像中往往比在同等物理尺寸的可见光图像中占据更少的像素，且边界更加模糊，现有的小目标检测方法在自然图像上积累的经验，能否直接迁移到毫米波这一特殊模态，本身就是一个尚未有定论的前沿问题。团队的研发过程，某种程度上就是在验证、修正、适配这些方法在新模态上的有效性，这也是本项目区别于“套用

²被动毫米波实时成像仪的技术参数及其在违禁品检测任务中的应用，参见 Pang, L., Liu, H., Chen, Y., Miao, J. Real-time Concealed Object Detection from Passive Millimeter Wave Images Based on the YOLOv3 Algorithm[J]. Sensors, 2020, 20(6): 1678.

现成算法”的关键前沿性所在。

2. 多学科交叉：计算机视觉、嵌入式工程与安检行业需求的协同攻关

2.1 算法设计与嵌入式硬件约束的双向适配

本项目的交叉性首先体现在计算机视觉算法设计必须与嵌入式硬件的算力、功耗约束进行双向适配，而非单向的“先设计最优算法、再想办法压缩”。团队在项目伊始就明确了硬件侧的边界条件：安检设备内置的边缘计算单元算力有限、散热条件有限、无法依赖云端算力实时回传，这意味着模型的每一次结构改动，都必须同时评估其对推理速度、显存占用、模型体积三方面的影响，而不能只关注检测精度这一单一指标。这种“算法—硬件协同设计”思路，正是嵌入式人工智能系统区别于纯学术研究的核心工程特征：学术研究可以在无限算力假设下追求精度的极致，而工程落地必须在算力、功耗、成本的多重约束下寻找可行解。这也是本项目区别于单纯的计算机视觉算法论文、而更强调“嵌入式人工智能系统设计”这门课程所要训练的综合能力——学员不能只会在纸面上设计一个精度更高的网络结构，还需要理解这个结构最终要跑在什么样的硬件上、要付出怎样的部署代价。

2.2 与安检行业实际需求的对接

项目的第二重交叉性，体现在计算机视觉技术团队与安检设备企业、乃至一线安检从业人员之间的需求对接过程。团队没有闭门造车式地追求论文指标的极致优化，而是通过多轮实地走访与一线安检员座谈，围绕安检场景的真实痛点——大客流通过速度、误报率对安检员工作负荷的影响、漏报的安全后果——反复调整技术指标的优先级排序。例如，团队特别关注了模型在“召回率”（尽量不漏检）与“精确率”（尽量不误报）之间的平衡：对于安检这一安全敏感场景，漏检的代价远高于误报的代价，这就要求团队在超参数调优、损失函数设计等环节，有意识地向召回率倾斜，而非简单地以综合指标 mAP 最大化为唯一优化目标。这种“技术指标服从行业实际需求”的工程思维，是计算机专业学位学员在课堂上较少接触、却在实际工程项目中至关重要的能力。

2.3 跨学科团队的组织方式

本项目的交叉性也体现在团队自身的组织构成上：项目团队并非单一的算法研发小组，而是由计算机视觉算法工程师、嵌入式系统工程师、以及来自安检设备企业的

产品与行业专家共同组成的跨学科攻关团队。算法工程师负责模型结构设计与精度优化，嵌入式系统工程师负责推理框架适配、模型量化与硬件资源调度，行业专家则负责将安检场景的真实需求（如客流通过速度标准、误报率容忍阈值、不同违禁品类别的安全优先级）转译为可量化的技术指标，三方角色分工明确又高度依赖彼此的输入，缺一不可。三方团队通过定期的联合评审会议，将各自的专业判断汇聚到统一的技术路线决策中——例如，本案例第 4.1 节讨论的“哪些实验室指标容易掩盖现实问题”，正是行业专家基于一线部署经验向算法团队提出的关键反馈，如果没有这种跨学科的常态化协作机制，团队很可能在离线数据集上取得漂亮的指标后就误判项目已经“大功告成”，而忽视了实验室指标与真实部署效果之间可能存在的巨大鸿沟。

3. 关键技术难点与团队的路线抉择：四轮渐进式消融实验

团队将整个研发过程中反复权衡的核心矛盾归结为一句话：如何在几乎不损失、甚至提升检测精度的前提下，把模型体积和计算开销压下来？围绕这一矛盾，团队展开了四轮渐进式的结构改进与消融实验。

3.1 第一轮：基线模型的确立

团队首先跑通 YOLOv8 基础模型，不做任何结构改动，使用默认超参数进行训练，得到基线结果：模型计算量 8.1 GFLOPs，模型体积 6.2MB，在测试集上取得召回率 0.854、mAP50 为 0.931、mAP50-95 为 0.764 的精度水平。这一基线结果成为后续所有改进方案的对照基准——任何后续改动，都必须在速度/体积、mAP50、mAP50-95 这三项指标上讲清楚“改进了什么、牺牲了什么”，这正是结构化消融实验方法论的核心要求。

3.2 第二轮：主干网络轻量化——GSConv 替换 Backbone

团队首先尝试的改进方向是主干网络轻量化，引入 GSConv（Group-wise and Shuffle Convolution，分组混洗卷积）替换原始的标准卷积模块³。GSConv 通过分组卷积降低参数量与计算量，同时保留通道混洗机制以缓解分组卷积带来的通道间信息隔离问题。改进后，计算量从 8.1 GFLOPs 降至 6.9 GFLOPs，模型体积从 6.2MB 降至 5.4MB，但令人意外的是，召回率不降反升，从 0.854 提升至 0.927——这一结果验证了团队的一个关键判断：在小目标检测任务中，参数量的减少不一定意味着特征表达能力的下降，关键在于轻量化模块是否保留了足够的跨通道信息交互能力。

³GSConv 与 Slim-Neck 方法参见 Li, H., Li, J., Wei, H., Liu, Z., Zhan, Z., Ren, Q. Slim-neck by GSConv: A lightweight-design for real-time detector architectures[J]. Journal of Real-Time Image Processing, 2024. (arXiv:2206.02424)

从工程决策记录的角度看，团队在项目日志中明确写下了这一轮实验的预期与实际结果对比：预期是”计算量下降、精度小幅下滑，属于可接受的效率—精度权衡”，实际结果却是”计算量下降、精度不降反升”，这种预期与实际结果之间的落差，恰恰是推动团队进一步深挖技术原理、而不是简单”见好就收”的直接动因。这一”反直觉”结果的技术原理值得展开说明：标准分组卷积虽然能够降低计算量，但会将输入特征图按通道分组后各自独立卷积，导致不同分组之间的信息无法交互，长期堆叠会削弱特征表达能力；GSConv 的设计精妙之处在于，它在分组卷积之后引入通道混洗（Channel Shuffle）操作，将不同分组的输出特征重新打散、混合排列，使得后续层能够访问到跨分组的特征信息，从而以较低的计算代价近似恢复标准卷积的跨通道信息交互能力。对于被动毫米波这类本身信息密度较低的图像模态而言，保留跨通道信息交互能力，可能比在自然图像任务中更为关键——这也解释了为什么 GSConv 在本任务上取得的精度提升幅度，超过了它在常规自然图像检测任务中通常展现的效果。

团队在这一轮实验中还做了一个容易被忽视、但同样具有教学价值的对照测试：仅使用分组卷积而不引入通道混洗操作。结果显示，在缺少通道混洗的情况下，模型计算量同样有所下降，但召回率相较基线出现了小幅下滑，而非提升。这一对照实验直接证明了”提升效果的关键并非分组卷积本身，而是通道混洗恢复的跨通道信息交互能力”这一因果推断，而不是仅凭”用了 GSConv、指标变好了”就草率地把功劳归于整个模块，这种”拆解模块内部机制、逐一验证因果关系”的实验设计习惯，是区分严谨工程研究与简单调参试错的重要标志。

3.3 第三轮：“轻量化之后特征提取能力减弱”的担忧与 Slim-Neck 方案

尽管第二轮结果令人振奋，团队仍然清醒地意识到一个潜在的工程风险：主干网络轻量化之后，虽然降低了模型复杂度，但也可能导致模型在更深层次的特征提取能力上出现隐性减弱，只是在当前数据集与任务上尚未充分暴露。为应对这一潜在风险，团队在颈部网络引入 Slim-Neck 结构，通过精简化的特征金字塔设计⁴，强化对低层特征图的语义信息融合，弥补轻量化主干网络可能带来的细粒度特征损失。这一改动使 mAP50 从 0.93 进一步提升到 0.947，mAP50-95 提升至 0.781，验证了“用更高效的多尺度特征融合方式来补偿主干网络轻量化的潜在精度损失”这一技术路线是可行的。

3.4 第四轮：组合方案与检测头的取舍

⁴特征金字塔多尺度融合方法论的经典文献参见 Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., Belongie, S. Feature Pyramid Networks for Object Detection[C]. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017: 2117-2125.

团队进一步尝试将 GSConv 与 Slim-Neck 组合使用，并引入逐元素乘法模块增强特征交互，最终得到的组合方案在计算量降至 6.0 GFLOPs、模型体积压缩至 5.0MB 的同时，召回率达到 0.933，mAP50 达到 0.963，mAP50-95 达到 0.781，相比原始基线实现了“计算量下降约 26%，关键小目标检测精度不降反升”的目标。团队还尝试在此基础上叠加轻量化检测头 LADH（Lightweight Asymmetric Detection Head），虽然计算量进一步降至 5.6 GFLOPs，但 mAP50-95 从 0.781 回落至 0.79 附近波动、召回率出现小幅下降（0.891），团队据此判断：检测头层面的进一步轻量化已经触及了当前数据规模与任务复杂度下的性价比拐点，继续压缩检测头带来的边际算力收益，已经不足以覆盖其对精度稳定性的负面影响，因此最终方案保留了 GSConv+Slim-Neck+ 逐元素乘法的组合，未采纳 LADH 检测头改动。

表 1 四轮渐进式消融实验结果对比

方案	GFLOPs	模型体积 (MB)	召回率	mAP50	mAP50-95
基线（YOLOv8）	8.1	6.2	0.854	0.931	0.764
+GSConv	6.9	5.4	0.927	0.930	0.764
+Slim-Neck	—	—	—	0.947	0.781
+GSConv+Slim-Neck+ 逐元素乘法	6.0	5.0	0.933	0.963	0.781
+LADH 检测头	5.6	—	0.891	—	约 0.790

3.5 基线模型横向对比：为什么改进方案优于同代及新一代 YOLO 系列

为证明改进方案的技术先进性而非仅仅是“自说自话”，团队在相同数据集上复现并对比了 YOLOv5（参数量约 703 万，15.8 GFLOPs，mAP50 为 0.933，mAP50-95 为 0.735）、YOLOv7（参数量约 602 万，13.2 GFLOPs）等基线模型，以及 Faster R-CNN、SSD、RetinaNet、CenterNet、FCOS 等经典与前沿检测框架。对比结果显示，团队改进后的方案在计算量和模型体积上远低于 YOLOv5、YOLOv7 等模型，而在 mAP50-95 这一更能反映小目标检测精度的指标上持平甚至反超，证明了轻量化改进并未以牺牲检测可靠性为代价换取速度提升，这也是本案例”典型性”要求中”代表技术选取和路线革新一般规律”的具体体现——改进方案不是孤立的个案优化，而是可以在同一评价体系下与主流方案进行横向对比、且经得起对比检验的技术路线。

值得说明的是，团队在横向对比实验中严格控制了训练数据集、训练轮数、硬件环境等变量的一致性，确保各基线模型是在完全相同的实验条件下复现的，而非直接引用不同论文中在不同数据集上报告的指标进行”跨数据集比较”——这是工程对比实验中容易被忽视、却直接决定对比结论是否可信的一个细节。学员在自己的项目中

开展基线对比时，同样需要警惕”表面上都是同一个数据集名称，但预处理方式、数据划分比例不一致”这类隐蔽的对比陷阱。

4. 典型性检验：从实验室到产线的部署与验证

4.1 部署环境与现场验证

模型训练完成后，团队将改进后的轻量化模型部署至安检设备内置的边缘计算单元，并针对实际部署场景进行了推理速度、误检率、漏检率的现场验证。这一步骤是本案“典型性”评价维度的核心：案例所呈现的技术路线是否真正取材于实际工程环境与核心难题，能否代表相关工程实践的技术选取和路线革新的一般规律，很大程度上取决于模型是否真正走出了实验室、在真实部署环境中经受住了检验，而非仅仅停留在离线数据集上的指标对比。

4.2 跨场景泛化的持续挑战

团队特别关注了两类容易被实验室指标掩盖的现实问题：一是被动毫米波图像在不同季节、不同厚度衣物条件下的成像差异，是否会导致模型在实验室数据集之外出现精度衰减；二是在真实客流通过速度下（而非静态测试图像），模型的实时推理帧率是否能够稳定维持在满足”不停顿通过”要求的水平。针对上述问题，团队采用了数据增强手段（饱和度、对比度、亮度、色相调整）扩充训练样本的场景多样性，并结合模型剪枝与量化技术进一步压缩推理耗时，以适配边缘计算硬件的算力约束。

围绕第一类问题，团队还专门设计了针对”厚衣物场景”的专项验证实验：冬季厚棉服会显著衰减毫米波信号穿透强度，使得原本就信息稀疏的成像质量进一步下降。团队通过在训练集中按季节比例针对性补充厚衣物样本、并引入基于信号强度的自适应对比度增强预处理步骤，将冬季场景下的检测召回率波动控制在了可接受范围内。这一处理思路提示学员：算法团队在评估模型泛化能力时，不能只满足于”数据增强”这一笼统概念，而应当针对具体应用场景中最容易导致数据分布偏移的现实变量（如本例中的季节性衣物厚度变化），设计有明确物理意义指向的针对性增强策略。

4.2.1 真实客流通过速度下的推理帧率验证

针对第二类问题，团队在真实地铁安检口场景下，以正常通勤客流的实际通过速度（而非人为放慢速度配合测试）采集了连续视频流数据，对模型的端到端推理帧率进行现场压力测试。测试发现，在未经量化压缩的原始模型上，边缘计算单元的推理帧率无法稳定满足实时性要求，存在明显的帧率抖动现象；经过 INT8 量化与结构化

剪枝处理后，推理帧率的稳定性显著提升，能够在绝大多数测试时段内满足”人体不停顿通过”场景的实时性门槛。这一验证过程表明，实验室环境下测得的单帧推理耗时，与真实部署环境下的端到端帧率稳定性之间，可能存在不可忽视的差距，这也是本案例反复强调”从实验室到产线”这一验证环节不可省略的现实原因。这一环节也再次印证了本案例的交叉性特征：模型压缩、量化部署本身就是计算机体系结构与深度学习算法交叉的技术领域，需要团队同时具备算法调优与嵌入式系统工程两方面的知识储备。

4.3 典型误检案例的复盘分析

在现场验证阶段，团队专门整理了一批典型误检与漏检案例进行归因分析，这也是工程类项目”典型性”评价维度的重要组成部分——一个真正具备推广价值的技术方案，不应止步于报告总体指标的提升，还需要对具体失败案例进行深入复盘。分析发现，误检情形主要集中在乘客身体姿态发生较大幅度扭转、或多人在安检口重叠通过的场景，这类场景下人体轮廓的毫米波成像特征会发生形变，与训练数据集中相对规整的姿态样本存在分布差异；漏检情形则主要出现在违禁品紧贴身体侧面、且被动毫米波信号强度较弱的边缘区域。团队据此在后续迭代中有针对性地扩充了包含上述边缘场景的训练样本，这一”发现问题一定位成因一针对性扩充数据”的闭环迭代方式，本身也是工程实践中比单纯追求模型结构创新更为常见、也更为重要的能力，也再次说明了工程项目的”典型性”不应止步于报告漂亮的平均指标，而要经得起对失败案例的追问。

4.4 工程可行性：轻量化改造带来的部署经济性

从工程可行性的角度看，模型体积从 6.2MB 压缩至 5.0MB、计算量下降约 26%，这些数字看似只是实验室报告中的技术指标，但在实际产品化落地中却有着直接的经济性意义：更小的模型体积意味着可以部署在成本更低、算力更弱的边缘计算芯片上，而不必为了运行一个”庞大”的模型被迫采购性能更强、价格也更高的硬件方案；更低的计算量则意味着单台设备的功耗更低、发热更少，这对于需要长时间连续运行的公共场所安检设备而言，直接关系到设备的散热设计成本与长期运维稳定性。团队在项目复盘时特别指出，这套轻量化方案使得设备制造成本降低到了此前部分同类产品方案的一定比例，这也是”典型性”评价维度所强调的”具备推广借鉴价值”在商业落地层面的具体体现——一项技术方案如果只能在昂贵的高端硬件上运行，其行业推广价值将大打折扣。

5. 复盘与启发：打破”轻量化必然牺牲精度”的工程直觉

5.1 方法论提炼：用特征融合补偿轻量化损失

本项目最核心的方法论价值，在于验证了一条可推广的技术路径：当轻量化改造面临“精度必然下降”的工程直觉阻力时，可以通过在特征融合层（Neck）引入更高效的多尺度语义融合结构，来主动补偿主干网络轻量化带来的潜在特征表达能力损失，而非被动接受精度与效率之间的简单负相关关系。这一思路不仅适用于毫米波安检场景，也可为其他资源受限边缘设备上的小目标检测任务（如工业质检、无人机巡检等）提供参考，这正是工程类案例“启发性”评价维度所要求的——对解决问题的方式方法进行复盘反思，并将其抽象概括为具备迁移应用价值的方法论，而不是停留在“某个项目做出了某个结果”的具体叙事层面。

5.2 边际收益递减：一次“没有采纳”的技术决策同样具有教学价值

团队最终放弃 LADH 检测头改动这一决策，同样值得反复咀嚼。工程实践中，“不能做”与“值不值得做”是两个完全不同的问题：LADH 检测头的引入在技术上完全可行，也确实能进一步压缩计算量，但团队通过严谨的消融实验发现，这一改动带来的精度损失已经超出了可接受范围，边际算力收益不足以覆盖精度稳定性的负面影响。这种“知道能做、但主动选择不做”的工程判断力，恰恰是工程教育中最容易被忽视、却在实际工作中至关重要的能力——真正成熟的工程决策，不是无止境地叠加所有可能的优化手段，而是清楚在哪个节点上应当停止。

5.3 从个案到方法论：工程类案例的知识迁移价值

将本项目的技术路线抽象到方法论层面，可以提炼出一条具有更广泛适用性的工程经验：面对“效率提升”与“性能保持”这对在几乎所有嵌入式 AI 系统中都会出现的矛盾，与其在单一网络层级（如仅仅压缩主干网络，或仅仅简化检测头）反复拉扯寻找折中点，不如系统性地审视整个网络的各个层级（主干网络—颈部特征融合—检测头），针对性地在最适合承担“效率—性能”再平衡任务的层级进行结构创新——本案例中，颈部特征融合层承担了这一再平衡的核心角色。这一方法论视角，不仅适用于目标检测任务，对于语义分割、姿态估计等其他计算机视觉任务在资源受限场景下的轻量化设计，同样具有借鉴意义，这正是工程类案例“启发性”要求中“支持知识的整合和迁移”的具体体现。

从更长远的工程教育视角看，本案例也提醒学员警惕一种常见的认知偏差：将“轻

量化”简单等同于”做减法”。团队的实践反复表明，真正有效的轻量化设计，往往是”结构性的减法与补偿性的加法”同时发生——在计算冗余的地方做减法（如 GSConv 对标准卷积的替换），同时在信息容易丢失的关键环节做加法（如 Slim-Neck 对多尺度特征融合的强化）。只有同时理解”该在哪里减、该在哪里补”，才能真正跳出”轻量化必然牺牲精度”这一朴素直觉的思维定式。

6. 总结与展望

本项目最终交付的轻量化违禁品检测系统，在计算量、模型体积均大幅压缩的前提下，实现了小目标检测精度不降反升的工程目标。团队也坦承当前方案仍存在局限：受限于被动毫米波公开数据集稀缺，模型在跨设备、跨场景泛化能力上的验证仍不充分；此外，检测头轻量化的”性价比拐点”判断目前主要基于当前数据规模下的实验观察，是否具有普适性，仍有待更大规模数据与更多应用场景的进一步检验。

面向未来，团队认为至少有两个方向值得进一步投入：其一，探索利用生成式模型合成更多样化的被动毫米波训练样本，缓解真实数据采集成本高、场景覆盖有限的约束——毫米波成像的物理成像过程相对可建模，这为仿真数据生成提供了一定的可行性基础，但仿真数据与真实数据之间的”域差异”如何弥合，仍是一个需要专门研究的问题；其二，探索跨模态融合方案，将被动毫米波图像与其他非侵入式传感手段（如热成像、可见光辅助定位）结合，进一步提升复杂场景下的检测鲁棒性。这些尚未完全解决的问题，也正是留给课堂讨论的开放空间：如果你是项目负责人，面对数据稀缺与泛化能力验证不充分这两个局限，你会优先投入资源解决哪一个？又会采用怎样的技术路线？这条从”精度与效率不可兼得”的工程直觉出发、最终以一套可复现的方法论作答的技术攻关之路，尚未走到终点，而是留下了一份等待后来者继续填写的开放答卷。

附录：消融实验完整数据与部署环境参数（酌情）

为便于课堂讨论时对照团队完整的技术决策链条，现将消融实验的完整数据与部署环境参数补充如下：

一、基线模型超参数设置（教学简化整理）：输入分辨率 640×640，训练轮数 300 epoch，优化器采用 SGD，初始学习率 0.01，批大小 16，数据增强包括马赛克增强、随机翻转、色彩空间扰动等标准 YOLO 系列训练配置。

二、SAIR-U 被动毫米波成像仪关键参数：工作频段 Ka 波段（约 34GHz），成像视场 40×22°，成像距离 2.5-5 米，温度灵敏度 1-2K，在 3 米成像距离处的空间分辨率约 5-6 厘米。

三、边缘计算部署环境（教学简化整理）：模型部署前经过 INT8 量化与结构化剪枝处理，推理框架采用面向嵌入式设备优化的推理引擎，实测单帧推理耗时可满足“人体不停顿通过”场景下的实时性要求。

四、团队消融实验设计的一般性方法论提炼：本案例展示的”基线 → 单点改进验证 → 潜在风险预判 → 组合方案优化 → 边际收益评估”五阶段渐进式消融实验设计，可作为学员在自己的工程项目中开展系统性技术选型与效果验证的通用方法论模板，不局限于目标检测这一具体任务。

五、关键技术模块简明对照表（教学整理，便于课堂讲解时快速引用）：

表 2 关键技术模块及其作用机理简明对照

技术模块	核心原理	在本案例中的作用
GSConv	分组卷积降低计算量 + 通道混洗恢复跨通道信息交互	主干网络轻量化，计算量下降约 15% 且召回率提升
Slim-Neck	精简化特征金字塔，强化多尺度语义融合	补偿主干网络轻量化带来的潜在精度损失
逐元素乘法	增强特征图之间的非线性交互	在组合方案中进一步提升 mAP50-95
LADH 检测头	轻量化非对称检测头设计	团队评估后判断性价比不足，最终未采纳

六、附录中呈现的完整消融数据与正文表 1 相互印证，教师可引导学员对照两张表格，尝试独立复现”基线 → GSConv → Slim-Neck → 组合方案 → LADH”这一完整技术演进链条的推理过程，训练学员阅读工程技术报告、复现技术决策逻辑的实务能力。

七、正文脚注引用文献汇总（按脚注编号顺序排列，与正文脚注共用同一编号序

列，供课堂讨论时统一查阅)：

[1] JOCHER G, CHAURASIA A, QIU J. Ultralytics YOLOv8[EB/OL]. GitHub, 2023.
<https://github.com/ultralytics/ultralytics>.

[2] PANG L, LIU H, CHEN Y, MIAO J. Real-time Concealed Object Detection from Passive Millimeter Wave Images Based on the YOLOv3 Algorithm[J]. Sensors, 2020, 20(6): 1678.

[3] LI H, LI J, WEI H, LIU Z, ZHAN Z, REN Q. Slim-neck by GSConv: A lightweight-design for real-time detector architectures[J]. Journal of Real-Time Image Processing, 2024. (arXiv:2206.02424)

[4] LIN T Y, DOLLÁR P, GIRSHICK R, HE K, HARIHARAN B, BELONGIE S. Feature Pyramid Networks for Object Detection[C]//IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017: 2117-2125.